



Relatório de Projeto

Residência Tecnológica

Projeto:

Análise de Sentimentos Baseada em Aspectos

Residentes:

Caio Mateus

Gabriel Buzzi Sanches

Silvio Lima

04/02/2024

Histórico de Revisões

Data	Versão	Descrição
04/02/2024	1.0	Primeira entrega do relatório de projeto.

Conteúdo

1. Objetivo do documento	3
2. Introdução	3
3. Motivação do projeto	4
4. Desenvolvimento	4
4.1. Descrição das abordagens existentes	5
4.2. Definição inicial da abordagem	6
4.3. Definição inicial da baseline	6
4.4. Definição inicial dos datasets	7
4.5. Definição inicial da avaliação	8
5. Referências	8

1. Objetivo do documento

Este relatório apresenta o trabalho realizado no projeto até a presente data. Novas informações e resultados serão incluídos em novas versões do documento.

2. Introdução

As informações desta seção serão incluídas durante a execução do projeto.

Com a chegada da era digital, grande parte do que é comprado ou vendido se dá pela internet. Reviews de usuários, comentários em redes sociais e pesquisas de opinião se tornaram o principal canal de comunicação entre as empresas e seus clientes. Mas toda essa facilidade para expressar opiniões sobre produtos sobrecarregou esse canal tornando informações de valor novamente inacessíveis aos vendedores de produtos e serviços. Por isso se torna necessária uma forma de extrair informações relevantes a partir de um grande volume de dados, algo que, por sinal, modelos de inteligência artificial são capazes de fazer com maestria. Disso surge a Análise de Sentimentos: metodologias de análise de dados que utiliza algoritmos de inteligência artificial capazes de extrair apenas aquilo que é relevante para quem recebe feedbacks de um produto ou serviço.

Mas sabemos que a opinião de um cliente nem sempre é única com relação a um produto ou serviço, ele pode avaliar um aspecto do produto de forma positiva, mas não gostar tanto de outro. Diante disso surge uma necessidade de refinar as metodologias de análise de sentimento. Surge então a análise de sentimento baseada em aspecto, que é capaz não só de classificar uma opinião, mas sim de classificar a opinião sobre cada aspecto mencionado no feedback. Por exemplo: “O carro é muito potente, mas consome muita gasolina”, é entendido pelo sistema como Potência -> Boa, Consumo -> Ruim.

Entretanto, este resultado refinado exige modelos de inteligência artificial mais complexos que por sua vez exigem grandes quantidades de dados, que nem sempre estão disponíveis, sobretudo diante da grande variedade de contextos

comerciais onde pode se desejar aplicar a solução. Felizmente com o desenvolvimento de modelos de linguagem pré-treinados como BERT e GPT torna-se possível resolver a Análise de sentimentos baseada em aspectos com poucos ou nenhum dados para treinamento prévio do modelo.

O presente projeto incorpora então o estudo e a implementação de uma solução para ASBA no paradigma de few- ou zero-shot-learning, ou seja, com poucos ou nenhum exemplo para treinamento prévio, um sistema que possa ser diretamente aplicado em qualquer domínio de interesse e apresenta resultados satisfatórios.

3. Motivação do projeto

Toda empresa para se manter competitiva no mercado precisa oferecer serviços ou produtos que atendam exatamente as expectativas de seus clientes, a fim de não os perder para concorrentes. Portanto, monitorar o que os clientes comentam a respeito da empresa ou produtos é vital para que o relacionamento positivo com o cliente seja mantido ou aperfeiçoado.

A técnica de Análise de Sentimento baseada em aspectos (Aspect Based Sentiment Analysis / ABSA) permite que empresas obtenham uma análise detalhada de dados vindos de clientes de forma que elas podem aprender mais a respeito das expectativas dos seus clientes, corrigir características mal avaliadas de seus produtos, manter ou aperfeiçoar aquilo visto como positivo e assim garantir a satisfação do cliente na compra do serviço ou produto.

4. Desenvolvimento

As informações desta seção serão incluídas durante a execução do projeto.

O projeto se inicia com uma revisão literária do problema de Análise de Sentimentos Baseada em Aspecto [1, 2, 3] visando a contextualização do problema, a familiarização do grupo com alguns dos caminhos de solução existentes, datasets

comumente utilizados, modelos adotados, metodologias de treinamento, testes e avaliação dos sistemas. Nesta etapa o grupo desenvolveu uma tabela para organização das leituras onde registra-se cada artigo lido bem como uma breve descrição da metodologia adotada, assim o registro das leituras fica centralizado para que todo o grupo tenha acesso ágil bem como controle do histórico de leituras.

4.1. Descrição das abordagens existentes

Diante do cenário de few- e zero-shot-learning as abordagens encontradas na literatura majoritariamente incorporam Modelos de Linguagem pré-treinados (Large Language Models – LLMs) [4, 5, 6, 7, 8, 9] utilizados de diferentes formas para atingir a ASBA. Em alguns casos faz-se a separação do problema em sub-tarefas como, por exemplo, Extração de Termos de Aspect e Classificação de Polaridade para determinado aspecto, mas em outros aborda-se de forma unificada (compound) [9] extraído em uma única passagem pelo modelo quais são os aspectos mencionados no review e suas respectivas polaridades.

Para as abordagens que envolvem fine-tuning de modelos de linguagem pré-treinados adota-se diversas formas de pré-processamento dos dados para alimentar o modelo, como, por exemplo, descrevendo a tarefa a ser executada em linguagem natural [3, 4], fornecendo ou não o alvo ou a categoria de interesse; seguindo o paradigma de question-answer (QA); seguindo o paradigma de natural language inference (NLI) [5]; ou ainda utilizando modelos generativos [6, 9] que classificam os sentimentos gerando ou completando sentenças em linguagem natural.

Foi comprovado em [9, 10] que complementar os exemplos com a descrição da tarefa (prompt) (input) e modelar os targets (output) em linguagem natural melhoram o desempenho do modelo uma vez que seu “conhecimento” adquirido na etapa de pré-treinamento pode ser melhor aproveitado.

4.2. Definição inicial da abordagem

A abordagem a ser adotada inicialmente no projeto trata-se de fazer o treinamento (fine-tuning) do modelo de linguagem pré-treinado open-source da Meta, o Llama, combinando as técnicas de prompt desenvolvidas em [4] e [9]. Na entrada do modelo será fornecido o review que se deseja avaliar concatenado com uma instrução que seguirá o modelo de instrução aplicado durante o pré-treinamento do Llama e na saída espera-se que o modelo construa uma paráfrase em linguagem natural do review seguindo um formato (template) pré-estabelecido que permita que os elementos da ASBA, neste caso Termo do Aspecto, Termo da Opinião e Polaridade da Opinião, possam ser extraídos sempre das mesmas posições nestas paráfrases na saída.

Diante a proposta de few-shot e zero-shot, o modelo será treinado com exemplos contendo tanto alguns reviews e sua respectiva resposta dentro do próprio prompt de entrada para servir como exemplificação da instrução fornecida (few-shot learning), quanto exemplos contendo apenas a instrução e o review de interesse (zero-shot learning). Os dados descritos na seção 4.4 deste documento também permitem que os cenários de cross-domain sejam simulados em zero- ou few-shot learning.

4.3. Definição inicial da baseline

Nossa *baseline* será o modelo Llama cru, sem que seja feito o fine-tuning para a tarefa em questão, assim poderemos inferir se nosso treinamento está sendo eficaz e melhorando a performance do modelo na execução da tarefa. Serão fornecidos os mesmos prompts desenvolvidos no fine-tuning para que as saídas sejam comparadas.

4.4. Definição inicial dos datasets

Tabela 1: Datasets inicialmente selecionados para treinamento e teste do sistema					
#	Dataset	Artigo	Fonte	Domínios	Língua
1	ASTE	[11]	SE-14 Restaurants; SE-15 Restaurants; SE-16 Restaurants; SE-14 Laptops;	Laptops Restaurantes	Inglês
2	DM-ASTE	[12]	Amazon	Electronics; Fashion; Beauty; Home; Book; Pet; Toy; Grocery	Inglês
3	MAMS	[13]	Original	Restaurante	Inglês

Foram selecionados 4 datasets com o objetivo de estimular ao máximo as capacidades do modelo, tanto quanto a complexidade dos exemplos quanto a variedade de domínios.

O dataset número 1 é uma combinação dos quatro datasets mais utilizados na literatura (SE-14 Restaurants; SE-15 Restaurants; SE-16 Restaurants; e SE-14 Laptops), porém adaptado em [11] para a tarefa Aspect–Opinion Triplet Extraction, que é a tarefa que se deseja executar neste projeto.

O dataset número 2 é um dataset de reviews de produtos de domínios variados comprados online na Amazon.com, este dataset foi escolhido para treinar e avaliar a generalização para diferentes domínios do modelo.

O dataset número 3 é um dataset de exemplos com maior complexidade, onde cada revisão contém pelo menos dois aspectos avaliados com polaridades diferentes, fazendo assim com que não haja risco do modelo transformar a tarefa em uma simples análise de sentimentos a nível de sentença.

4.5. Definição inicial da avaliação

A avaliação do sistema será feita pela métrica F1 Score pois é a métrica mais utilizada na literatura revisada. Para avaliar a capacidade de generalização para diferentes domínios do modelo dados domínios nunca vistos durante o treinamento serão introduzidos nos testes. Diferentes combinações de dados para treinamento e teste considerando quantidade de exemplos, polaridade e domínio serão adotadas a fim de extrair maiores conclusões das capacidades do modelo.

5. Referências

- [1] ZHANG, Wenxuan et al. A survey on aspect-based sentiment analysis: Tasks, methods, and challenges. IEEE Transactions on Knowledge and Data Engineering, 2022.
- [2] DENNY, Paul et al. A Systematic Review of Aspect-based Sentiment Analysis (ABSA): Domains, Methods, and Trends. arXiv preprint arXiv:2311.10777, 2023.
- [3] LASKARI, Naveen Kumar; SANAMPUDI, Suresh Kumar. Aspect based sentiment analysis survey. IOSR Journal of Computer Engineering (IOSR-JCE), v. 18, n. 2, p. 24-28, 2016.
- [4] SCARIA, Kevin et al. Instructabsa: Instruction learning for aspect based sentiment analysis. arXiv preprint arXiv:2302.08624, 2023.
- [5] SHU, Lei et al. Zero-shot aspect-based sentiment analysis. arXiv preprint arXiv:2202.01924, 2022.
- [6] LIU, Jian et al. Solving aspect category sentiment analysis as a text generation task. arXiv preprint arXiv:2110.07310, 2021.

-
- [7] MUFFO, Matteo et al. SBERTiment: A New Pipeline to Solve Aspect Based Sentiment Analysis in the Zero-Shot Setting. In: The International FLAIRS Conference Proceedings. 2023.
- [8] VARIA, Siddharth et al. Instruction tuning for few-shot aspect-based sentiment analysis. arXiv preprint arXiv:2210.06629, 2022.
- [9] ZHANG, Wenxuan et al. Aspect sentiment quad prediction as paraphrase generation. arXiv preprint arXiv:2110.00796, 2021.
- [10] SIMMERING, Paul F.; HUOVIALA, Paavo. Large language models for aspect-based sentiment analysis. arXiv preprint arXiv:2310.18025, 2023.
- [11] XU, Lu et al. Position-aware tagging for aspect sentiment triplet extraction. arXiv preprint arXiv:2010.02609, 2020.
- [12] XU, Ting et al. Measuring Your ASTE Models in The Wild: A Diversified Multi-domain Dataset For Aspect Sentiment Triplet Extraction. arXiv preprint arXiv:2305.17448, 2023.
- [13] JIANG, Qingnan et al. A challenge dataset and effective models for aspect-based sentiment analysis. In: Proceedings of the 2019 conference on empirical methods in natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP). 2019. p. 6280-6285.
- [14] SAEIDI, Marzieh et al. Sentihood: Targeted aspect based sentiment analysis dataset for urban neighbourhoods. arXiv preprint arXiv:1610.03771, 2016.